КРУГЛЫЙ СТОЛ · ТЕМА 5

CPU или GPU: кто победит в гонке AI-ускорителей?

Не лекция, а спор: у каждого слайда есть вопрос к залу

Кто решит задачу быстрее?

CPU

Один профессор математики

Решает любую сложную задачу, но по одной. Ядер от 4 до 64.

GPU

Класс из 10 000 школьников

Каждый умеет только простую арифметику, но считают все одновременно.

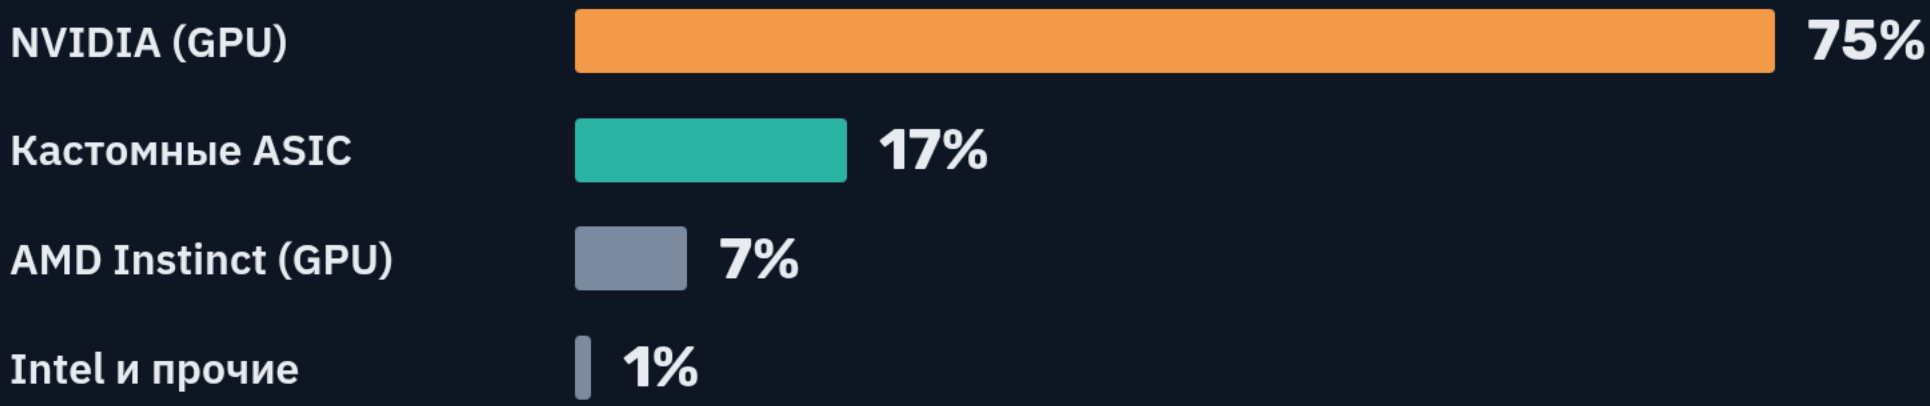
Задача: перемножить миллиарды матриц. Так устроено обучение нейросети.

ВОПРОС ЗАЛУ Кого вы наймёте для обучения нейросети? А для чат-бота на ноутбуке?

Метафора из материалов чата (скриншот автора)

Деньги уже у GPU?

Доли выручки ускорителей для дата-центров, 2026



Другие аналитики дают NVIDIA больше 90%. По отчёту NVIDIA, дата-центры — 92% её выручки (89,0 млрд $ за квартал).

ВОПРОС ЗАЛУ Если деньги у GPU, зачем вообще нужны CPU в ИИ?

Источники: диаграмма из чата (скриншот автора), Introl, пресс-релиз NVIDIA от 26 августа 2026

Угадайте: кто быстрее?

Один ноутбук, 4 ГБ видеопамяти. Две задачи, и в каждой CPU против GPU.

ЗАДАЧА 1

Распознать объекты на видео

Нейросеть YOLOv8s, занимает около 1 ГБ памяти.

ЗАДАЧА 2

Запустить языковую модель

Llama-3-8B, нужно около 5 ГБ памяти.

ВОПРОС ЗАЛУ Поднимите руку: в какой задаче выиграет CPU, а в какой GPU?

Тест из исследования (таблица 1, скриншот автора) · ответ на следующем слайде

Ответ: решает память

YOLOV8S: ВЛЕЗАЕТ В VRAM

4,4× быстрее у GPU

2,9× кадров на ватт у GPU

LLAMA-3-8B: НЕ ВЛЕЗАЕТ В 4 ГБ

2,9× быстрее у CPU

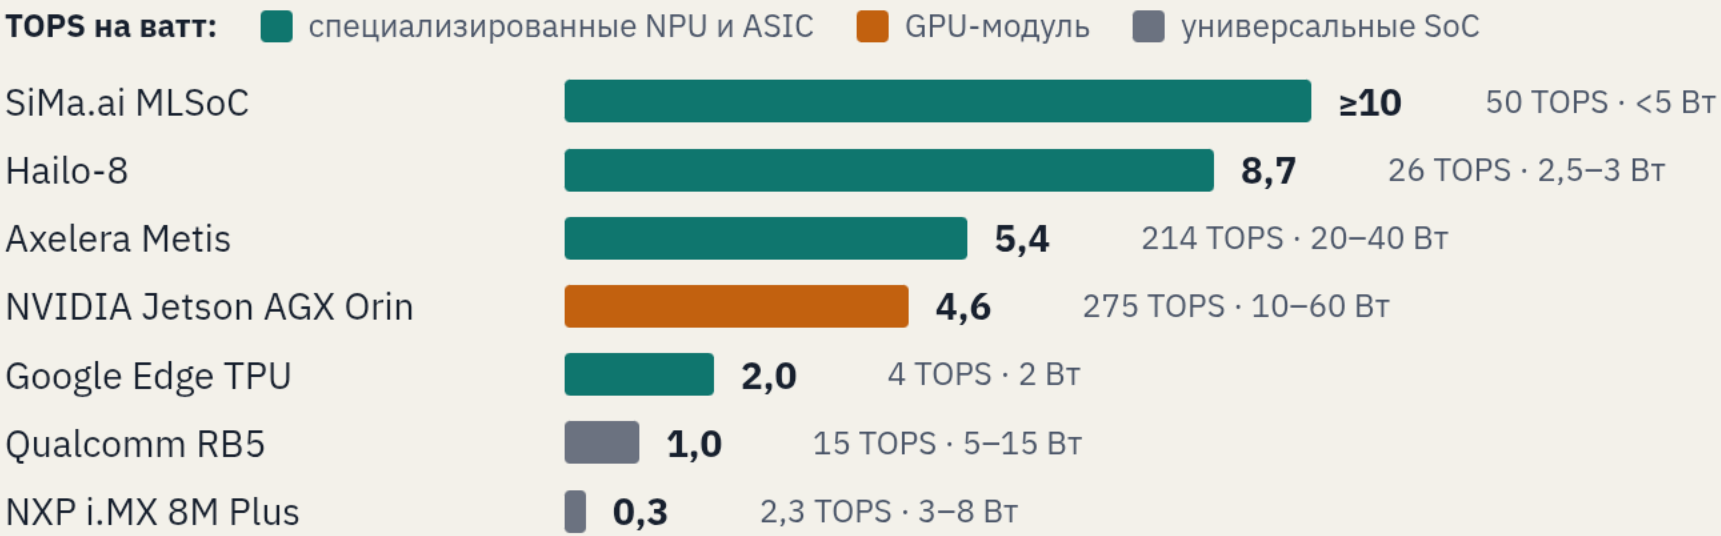
4,3× токенов на ватт у CPU

GPU выигрывает, пока задача помещается в его память.

ВОПРОС ЗАЛУ Если решает память, кто выигрывает на самом деле: производитель чипов или производитель памяти?

Расчёт по таблице теста (середины диапазонов мощности); один ноутбучный стенд, не дата-центр

А если оба проигрывают?



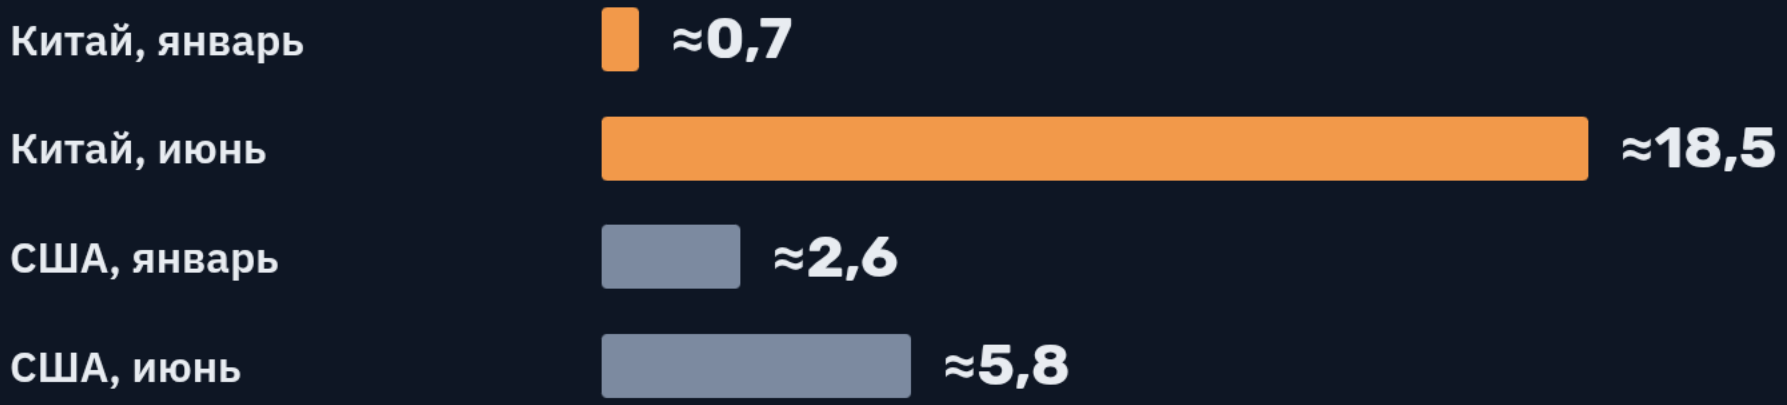
Мощность — максимум из диапазона таблицы; TOPS — заявления производителей; расчёт и цвета мои.

ВОПРОС ЗАЛУ Почему чип на 3 Вт эффективнее мощного GPU, и кому тогда достанется рынок?

Источник: таблица ускорителей из статьи (скриншот автора)

Токенов всё больше

Трлн токенов в неделю на OpenRouter, девять крупнейших моделей



Это спрос на инференс, а не доли рынка чипов; значения считаны с графика приблизительно.

ВОПРОС ЗАЛУ Что важнее: самый быстрый чип или самый дешёвый токен?

Источник: график OpenRouter по материалу smart-lab.ru (скриншот автора)

Согласны? Четыре спорных тезиса

1. «Через два года видеокарта в ноутбуке не нужна: хватит NPU»

NPU уже в 54,7% ПК 2026 года, но ПК покупают не из-за ИИ (Gartner, в пересказе).

2. «NVIDIA держит рынок не железом, а CUDA»

CUDA с 2006 года, но ИИ-выручка Broadcom за год выросла на 221%.

3. «ИИ упрётся не в чипы, а в память и электричество»

HBM на 2026 год по сообщениям распродана, GPU для ЦОД ждут 36–52 недели.

4. «Агентный ИИ вернёт CPU в центр»

TrendForce: на GPU придётся в разы больше CPU, срок поставки CPU вырос до 25–30 недель.

ГОЛОСУЕМ Согласны или нет? Несогласные объясняют почему.

Источники: Gartner, Broadcom, TrendForce, обзоры рынка памяти (в пересказе)

НАША ПОЗИЦИЯ

Единого победителя нет: всё зависит от задачи

GPU

Деньги и обучение

75% и больше выручки ускорителей.

ASIC И NPU

Эффективность

5–10 TOPS/Вт против 0,3–1 у универсальных SoC.

CPU

Память и управление

Быстрее GPU, когда модель не влезает в VRAM.

ВАШ ХОД

На что вы поставите в 2027 году: на CPU, на GPU или на третий путь?

Вывод на основе слайдов 3–7

Резерв: CPU и GPU в цифрах

Характеристика	CPU	GPU
Количество ядер	~4–64	до 10 000
Обработка данных	Последовательная	Параллельная
Оптимизация	Универсальные задачи, сложная логика	Параллельные вычисления, матричные операции
Пропускная способность памяти	до 100 ГБ/с	до 1,5 ТБ/с
Энергоэффективность	~0,01 Тфлопс/Вт	~0,5–1,25 Тфлопс/Вт

> Разрыв в энергоэффективности: 50–125 раз по этой таблице, 10–50 раз в другом материале. Важен порядок величины, а не точная цифра.

Источник: сравнительная таблица CPU и GPU из статьи (скриншот автора); значения типичные, у топовых ускорителей выше

Резерв: кто за что отвечает

Критерий	CPU	GPU
Основная роль	Универсальные вычисления и управление системой	Параллельные вычисления
Типичная нагрузка	Сайты, API, БД, CRM, очереди, мониторинг, CI/CD	AI/ML, инференс, рендеринг, видео, компьютерное зрение
Что важнее при выборе	Частота, IPC, кэш, память, ввод-вывод	VRAM, пропускная способность памяти, параллелизм
Что обычно дешевле	CPU-сервер	GPU-сервер почти всегда дороже
Порог входа	Низкий	Выше: нужен понятный сценарий применения

> Один не заменяет другого: CPU — базовый вычислительный слой, GPU — ускоритель под определённый класс задач.

Источник: сравнительная таблица CPU и GPU по критериям выбора на 2026 год (скриншот автора)

Резерв: таблица теста инференса

Модель	Вычислитель	Скорость	Память	Мощность
YOLOv8s FP32	CPU (AVX2)	12,4 FPS	1,1 ГБ RAM	35–45 Вт
YOLOv8s FP32	GPU (CUDA)	54,2 FPS	0,8 ГБ VRAM	55–65 Вт
Llama-3-8B Q4_K_M	CPU (12 потоков)	3,5 ток./с	5,2 ГБ RAM	45–50 Вт
Llama-3-8B Q4_K_M	GPU (offload)	1,2 ток./с	4,0 ГБ VRAM	65–75 Вт

Llama-3-8B требует около 5 ГБ, а видеопамяти доступно 4 ГБ: переполнение и обращение к shared VRAM снижают скорость на 30–50% относительно чистого CPU. Частичный перенос весов на GPU дал 2,3 ток./с, но задержка первого токена выросла до 2–3 секунд из-за шины PCIe.

Расхождение в самом источнике: в таблице 1,2 ток./с для GPU, в тексте — 2,3 ток./с. Стенд ноутбучного класса, не дата-центр.

Источник: таблица 1 «Сравнительные характеристики инференса моделей» из исследования (скриншот автора)

Резерв: проверка цифр из чата

Утверждение из чата	Что нашлось в источниках	Что говорить
Маржа NVIDIA 85%	Валовая 75%, операционная около 66% (отчёт NVIDIA, 2 кв. FY2027)	Валовая маржа 75%
GPU забирают «две трети» денег	На диаграмме того же чата 75%; в другом обзоре больше 90%	От 75 до 90%
Капитализация NVIDIA $3,6 трлн (график чата)	Около $5,65 трлн на 5 октября 2026 (InvestingCube)	График не использовать
Бюджеты Microsoft, Meta, Google $450 млрд	Капзатраты гиперскейлеров $660–690 млрд в 2026, около 75% на ИИ (Introl)	Диапазон с источником
Маржа производителей CPU около 60%	Валовая маржа AMD 54% во 2 кв. 2026 (отчёт AMD)	Для AMD — 54%
GPU эффективнее в 10–50 раз	Таблица: 0,01 против 0,5–1,25 Тфлопс/Вт, то есть 50–125 раз	«На порядок и больше»

Источники

Скриншоты автора: таблица CPU и GPU, таблица по критериям выбора, таблица edge-ускорителей, диаграмма долей выручки 2026, текст чата со слайдами и метафорой, таблица теста инференса, график OpenRouter (smart-lab.ru)

NVIDIA, итоги 2 кв. FY2027 — investor.nvidia.com (26 августа 2026)

AMD, итоги 2 кв. 2026 — ir.amd.com (4 августа 2026)

Introl, Custom Silicon Inflection Point (доля NVIDIA, капзатраты гиперскейлеров)

InvestingCube, крупнейшие компании по капитализации в 2026 году

Расчёты автора: TOPS на ватт, FPS и токены на ватт, отношения скоростей

Диаграмма капитализации NVIDIA и Intel из чата не использована: её значения не совпали с обзором InvestingCube.